### Screnscraping data, etl og normalisering

I denne opgave vil vi screenscrape en kilde på nettet og bruge de data vi finder til at lave en serie databaser, der i trin vil behandle de oplysninger vi har fundet. De enkelte trin i opgaven kan springes over, hvis teknikken volder dig kvaler er, er der i filer og beskrivelser der kan bringe dig videre.

### Læringsmålene er:

- 1. Programmering: PHP til screenscraping.
  - a. Screescraping teknologier i PHP
  - b. No OOP
  - c. Funktionel programmering no sideeffects.
- 2. Etablering af staging databaser
  - a. The BI way of doing it.
  - b. Datatype og type konvertering, Completeness.
  - c. Historik og batches.
  - d. Fysisk og Logisk databaselag, hvem arbejder med hvad?
- 3. Etablering ad RDMS
  - a. Normalformer og relationer
  - b. DDL,DQL,DML

Målet er at lande vores screenscraping data i en RDBMS

# Mainflow Wbbsite 1 extract cars\_stage.ext transform cars\_stage.dat a 3 load (your scripts) cars\_dbms.engines cars\_dbms.model

# Opgaven kan i sin helhed løses individuelt, i gruppe, eller som en øvelse i pair-programming.

Opgaven er beskrevet i afsnittet: Etablering ad RDBMS

Der hører to git repositorier til dette oplæg

https://github.com/kimo1ucl/Webscraping:

https://github.com/kimo1ucl/SQL-Datatypes-Normalization:

### Contents

Programmering: PHP til screenscraping	2
Etablering af staging databaser	2
Opgave: Etablering ad RDBMS	3
Instruks: PHP screenscraping	4
Instruks: Etablering af stage og template database	5
Stage database	6
Template database	7
Instruks: Anvendelse af template database	8
Development Integration: Seed og Edit	8
Development Integration: Generate database objects	10
Konklusion om replika et BI udviklingsflow	13
Afprøvning: Rådata ETL	13

### Screnscraping data, etl og normalisering

### Programmering: PHP til screenscraping.

Sceenscraping er noget hvor PHP altid har skinnet! Specifikt til den disciplin har der længe eksisteret frameworks i PHP, som man i en Windows virksomhed måtte kigge langt efter. Vi ser på en interssant artikel der beskæftiger sig med at afprøve der forskellige teknologier.

https://github.com/kimo1ucl/Webscraping: Kode du kan downloade og prøve selv.

Men husk, at hvis der er forudsætninger som frameworks, så skal de også installeres for at download koden fungerer. Enkelte kræver installation af filer på dit operativ system, men mange danner alene filer i det projekt du arbejder med.

Når du installerer et framework, installerer du oftest kun filer i den mappe hvorfra du eksekverer. Der dannes en mappe: 'vendor'. I 'vendor' mappen ser du mapper og kildekode, som det blev hentet/opdateret sidste gang kommandoen 'composer require <framework>' blev kørt fra roden af webprojektet. Kræver disse framework installation af filer på operativsystemet, skal man være meget grundig med at registrere afhængigheden. Oplysninger af denne art er design dokumentatiom, og skal bruges hver gang en ny server i et givent miljø skal konfigureres.

# Etablering af staging databaser

Vi skal have importeret vores udtræk. I første omgang handler det om at få alle kollonner og alle rækker med. Vi importerer til en tabel vi vil kalde noget med 'ext', så ved vi at dette er vores 'Extraction' database. Alle kolonner er en overdimensioneret string type, fordi vi kompromiløst vil have data fra fil og ind i databasen. Derfra kan vi langt lettere lokalisere fejl og forekomster.

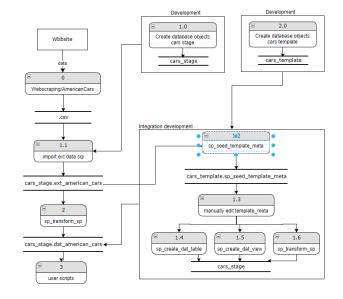
I det næste trin skal vi type konvertere, fordi i første omgang importerede vi bare det hele som strings.

- Kolonne for kolonne skal vi bestemme
  - o passende datatype.
  - o Om der er behov for datatranform

Database objekterne vi arbejder med i det videre forløb er views og stored procedures, i en replika af arbejdsgangen i et BI udviklingsflow hvor vi arbejder med rådata. Fra en 'cars\_template' database genererer vi de nødvendige database objekter, der skal realisere en extract, transform, load proces så data lander i vores dat (for data) tabel.

I dfd diagrammet er det færdige load præsentret til venstre, til højre er er udviklingsindsats.

I repositoriet til denne del finder du komplet source kode, som du blot skal eksekvere mod din mysgl server.



Læser du scriptsene ser du masser af SQL som du grundlæggende lærer fra w3school sitet mfl.

# American Cars Database Case Screnscraping data, etl og normalisering

### **Opgave**: Etablering ad RDBMS

Vi skal have fundet sammenhænge i vores data. Klart at det handler om amerikanske biler i forskellige mærker, men givet at vi vil have data repræsenteret i en relationel database på 3. normal form, dvs. At vi forventer en tabel som feks. 'Make' hvor der i rækkerne står Ford, Chevrolet, Cadillac. En anden tabel der helt sikkert også springer i øjnene er Model. Men hvordan med Make, Model og motortype? Ford har vel en serie motorer, men hvordan så med denne motor og de forskellige modeller? Er farveskemaerne Model eller Make specifikke?

Du skal lave script(s) der kopierer data fra cars\_stage.dat\_ til tabeller, du også selv designer og danner, i cars\_rdbms databasen. Det kan være en god ide at dele scriptsene op i en ordnet sekvens, så du trinvist opbygger din samlede query.

Målet er at lande vores screenscraping data i en RDBMS med jeres forståelse af disse sammenhænge.

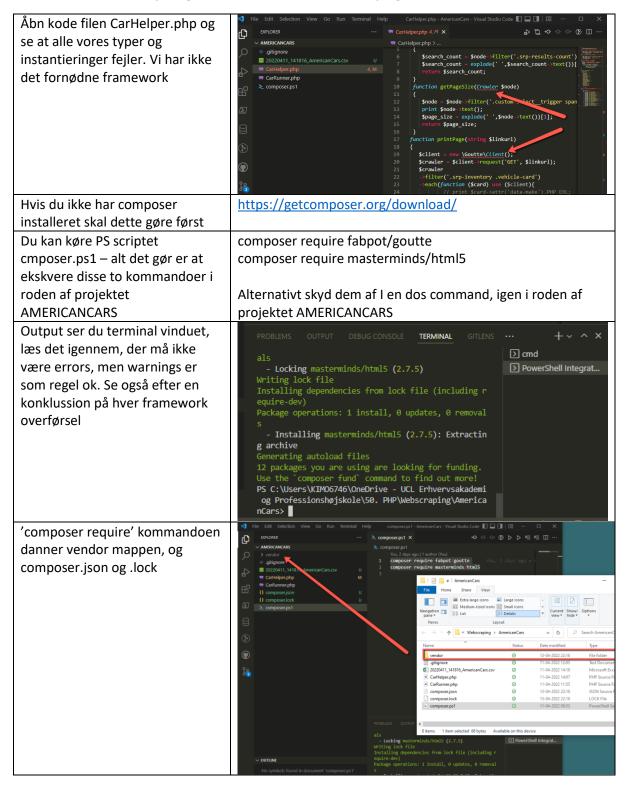
- Der er ikke en sand løsning til opgaven, det handler også om de muligheder du ser i anvendelsen af data og den måde de repræsenteret på. Hvilken kardianlitet ser du gælder?.
- I opgaven med at etablere rdbms skal du alene tage udgangspunkt i de data der er tilgængelige.
- Selvfølgelig må du ikke opdatere rådata. Men hvis du vælger en løsning med pseudo nøgler (autoid) må de(n) nødvendige kolonner selvfølgelig tilføjes.
- Opgaven sigter ikke mod en tilgang, hvor du er fremsynet, og tænker i overordnet modellering, sådan at vi kunne have mange webscrabes, der med dine SQL scripts mellem stage og rdbms database, kunne gemme data fra alle webscrabes. Dette er en rådata extract-trensform-load. Når data skal herfra og til BI brugerne vil man måske lave datamarts, eller noget powerbi til at lave en tilsvarende extract-transform-load abstraktion.

Screnscraping data, etl og normalisering

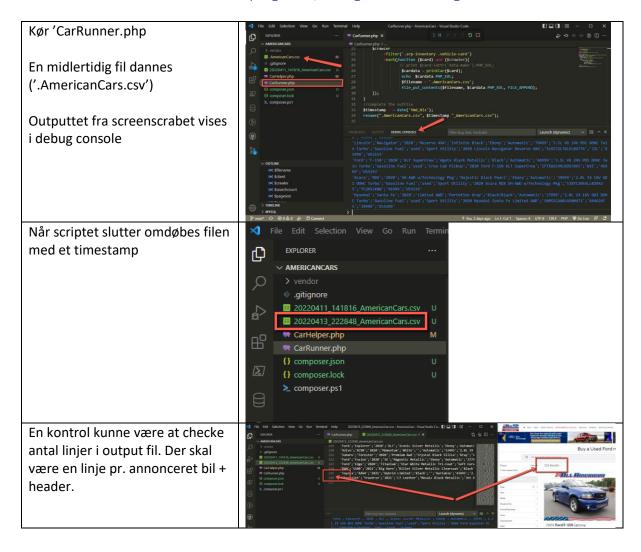
### Instruks: PHP screenscraping

Denne instruks hjælper dig med at ekskvere php screenscrabing af et website tilhørende end amerikansk brugtvognsforhandler der udstiller brugte biler til salg.

Download kode fra: https://github.com/kimo1ucl/Webscraping



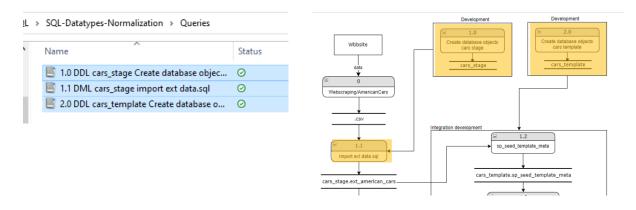
### Screnscraping data, etl og normalisering



# Instruks: Etablering af stage og template database

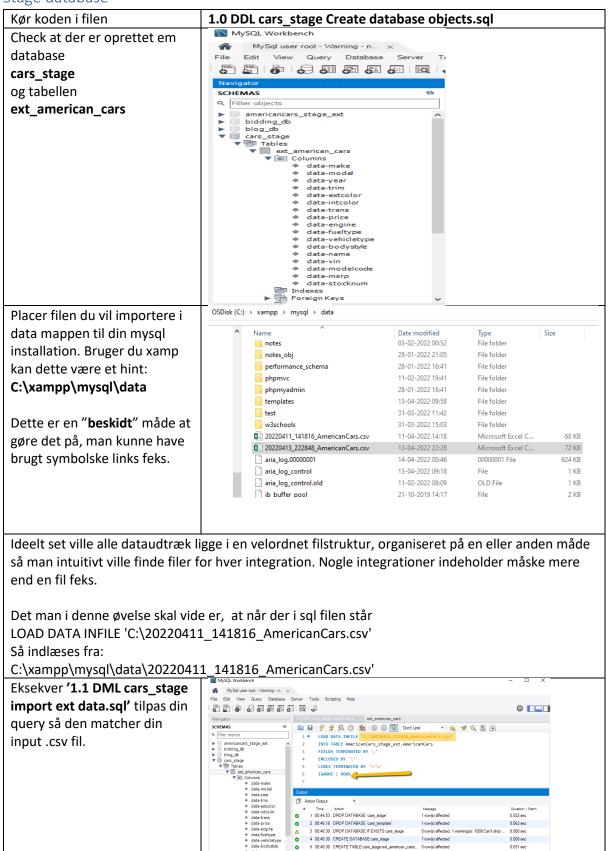
Nu skal vi arbejde med databaser. Alle scripts er lavet klar til eksekvering., alt hvad du skal gøre er at eksekvere dem. Find dem i mappen **Queries** 

Kildekoden kan du hente her: https://github.com/kimo1ucl/SQL-Datatypes-Normalization:

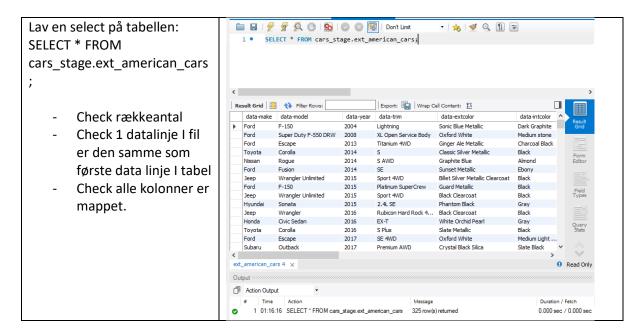


### Screnscraping data, etl og normalisering

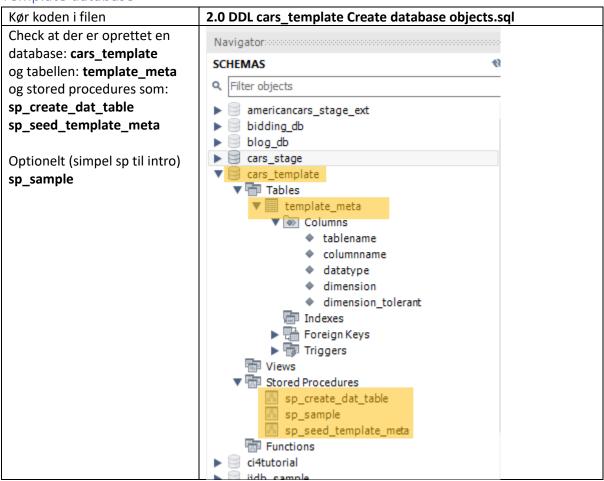
### Stage database



### Screnscraping data, etl og normalisering



### Template database

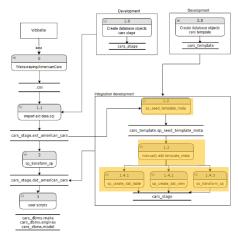


Screnscraping data, etl og normalisering

### Instruks: Anvendelse af template database

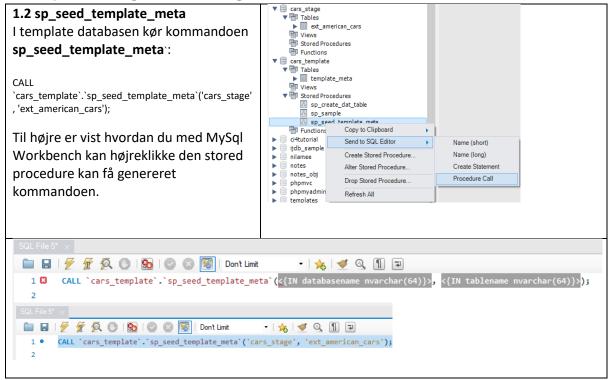
I øvelsen her skal vi bestemme os for datatyper til vores screen scrabing data. Hvor lange skal tekstrengene være? Hvordan er numeriske værdier repræsenteret?

Hvis vi dimensionerer vores datatyper så de eksakt passer den længste streng dr måtte være repræsenteret i en given kolonne, risikerer vi at vi i et af de følgende udtræk står med data der ikke passer til vores dimensionering fordi den var for snæver. Det er ofte en skønssag hvor meget ekstra vi vil tillade. I nogle tilfælde vil det fremgå at data kan have intet eller lidt varians, mens andre kolonner måske rummer data med meget stor varians i længde.

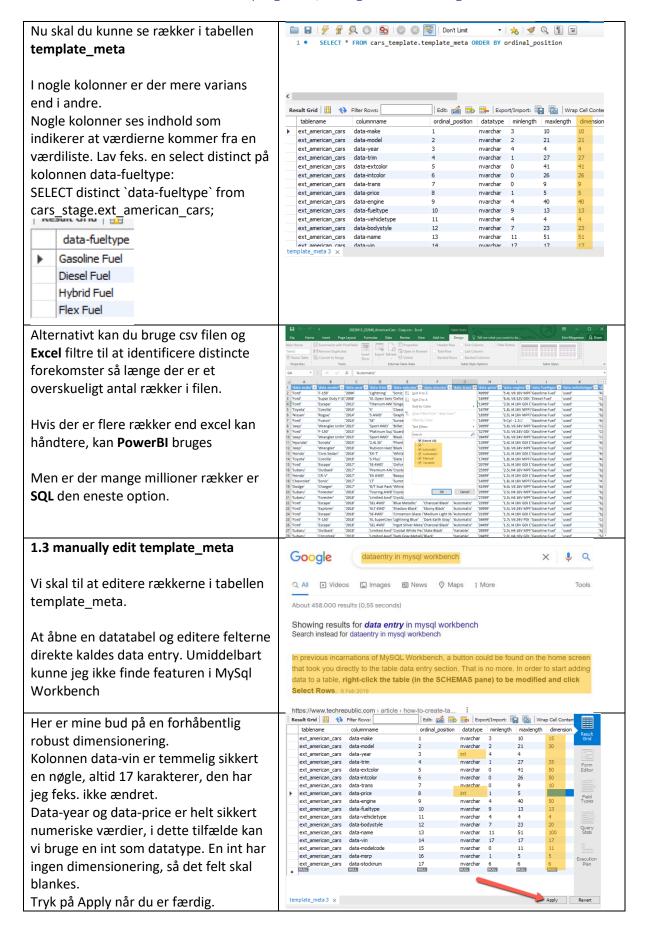


Vi vil "opdatere" vores beslutninger i tabellen template\_meta, derefter kan vi generere dataobjekter, der skal oprettes i stage databasen, og som skal anvendes hver gang data vi henter en ny datafil og data skal flyttes igennem ETL laget.

### Development Integration: Seed og Edit



### Screnscraping data, etl og normalisering



### Screnscraping data, etl og normalisering



### Development Integration: Generate database objects

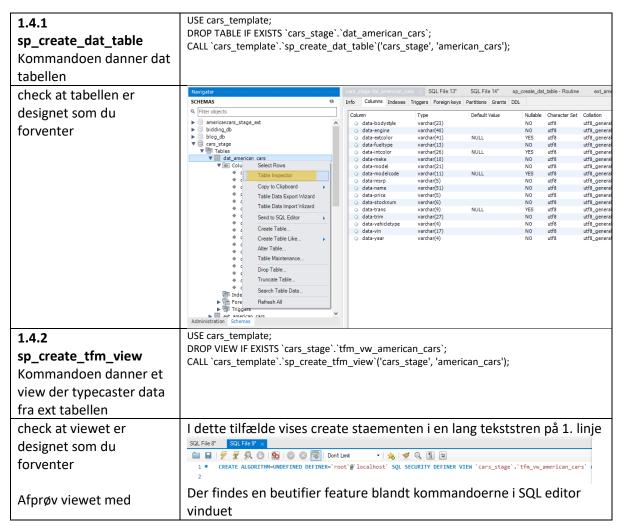
Her skal vi generere database objekter i cars\_stage databasen.

Vi ender op med en stored procedure, der kan kaldes med automatik eksekvering. Oracle og MSSQL server har selvstændige schedulere dedikeret denne use case.

Med MySql server vil man kunne lave en kommandolinje kommando afviklet i MySql CLI (command line interface) og lade operativ systemts scheduler klare opgaven.



Står MySql installationen på en Unix/Linux platform, ville crontab være et oplagt implementeringsrum for scheduleringen.



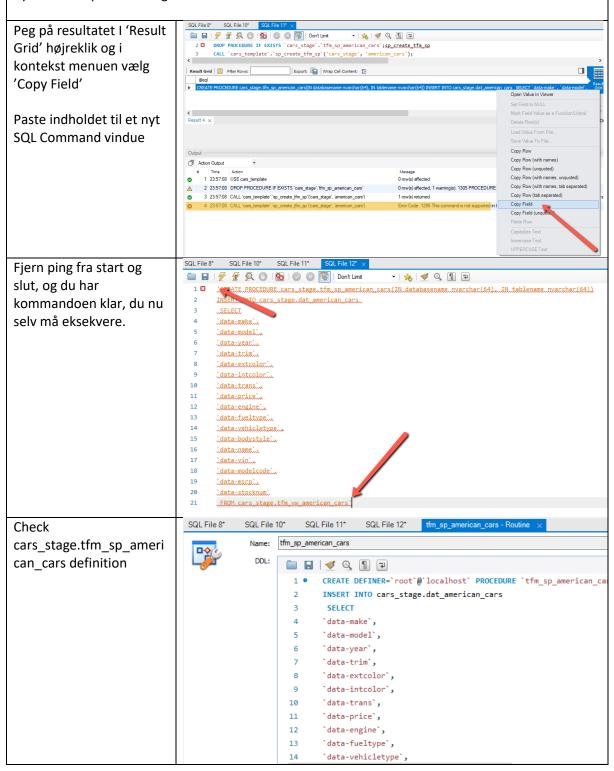
### Screnscraping data, etl og normalisering

```
SELECT * FROM
                                        SQL File 8* SQL File 9* X
                                          📗 📙 | 🍠 📆 👰 🕑 | 😘 | 💿 🚳 | Don't Limit
                                                                              - 🔀 🗹 🕽 🖘
                                                                                        IY DEFINER VIEW `cars_stage`.`tfm_vw_american_cars` AS select cast(`cars_stag
`cars_stage`.`tfm_vw_am
erican cars`
                                          🚞 🖫 | 🐓 💯 👰 🔘 | 🚱 | 🥥 🕲 🔞 | Don't Limit 🔻 | 埃 | 💇 🔍 🗻 💷
                                                      ALGORITHM = UNDEFINED
                                                      DEFINER = `root`@`localhost`
                                                      SOL SECURITY DEFINER
                                                  VIEW `cars_stage`.`tfm_vw_american_cars` AS
                                                      SELECT
                                            6
                                                          CAST(`cars_stage`.`ext_american_cars`.`data-make`
                                                              AS CHAR (15) CHARSET UTF8) AS 'data-make',
                                            9
                                                          CAST(`cars_stage`.`ext_american_cars`.`data-model`
                                           10
                                                              AS CHAR (30) CHARSET UTF8) AS 'data-model',
                                                          CAST('cars_stage'.'ext_american_cars'.'data-year'
                                           11
                                                             AS SIGNED) AS `data-year`,
                                                          CAST(`cars_stage`.`ext_american_cars`.`data-trim`
                                           13
                                           14
                                                               AS CHAR (35) CHARSET UTF8) AS `data-trim`,
                                                          CAST('cars stage'.'ext american cars'.'data-extcolor
                                           15
                                           16
                                                              AS CHAR (50) CHARSET UTF8) AS `data-extcolor`,
                                                          CAST('cars_stage'.'ext_american_cars'.'data-intcolor'
                                           17
                                           18
                                                              AS CHAR (50) CHARSET UTF8) AS `data-intcolor`,
                                           19
                                                          CAST('cars_stage'.'ext_american_cars'.'data-trans'
                                                              AS CHAR (10) CHARSET UTF8) AS `data-trans`,
                                           20
                                           21
                                                          CAST('cars_stage'.'ext_american_cars'.'data-price'
                                                              AS SIGNED) AS `data-price`,
                                           22
                                                          CAST('cars_stage'.'ext_american_cars'.'data-engine'
                                           23
                                                              AS CHAR (50) CHARSET UTF8) AS `data-engine`,
                                           24
                                           25
                                                          CAST(`cars_stage`.`ext_american_cars`.`data-fueltype`
                                                             AS CHAR (13) CHARSET UTF8) AS 'data-fueltype',
                                           26
                                           27
                                                          CAST('cars_stage'.'ext_american_cars'.'data-vehicletype
                                           28
                                                              AS CHAR (4) CHARSET UTF8) AS 'data-vehicletype',
                                           29
                                                          CAST('cars_stage'.'ext_american_cars'.'data-bodystyle
                                                               AS CHAR (30) CHARSET UTF8) AS `data-bodystyle`,
                                        USE cars template;
1.4.3 sp_create_tfm_sp
                                        DROP PROCEDURE IF EXISTS 'cars_stage'.'tfm_sp_american_cars';
Kommandoen danner en
                                        CALL `cars_template`.`sp_create_tfm_sp`('cars_stage', 'american_cars');
sp, der trækker data fra
ext tabellen gennem tfm
viewet og lander dem i
dat tabellen
                                        SQL File 8*
                                                 SQL File 10° SQL File 11°
I dette tilfælde får vi
                                                  Name: sp_create_tfm_sp
                                                                                                          The name of the routine is parsed automatically from the DDL statement. The DDL is parsed automatically while you type.
denne fejlkode:
                                                       Error Code: 1295 This
                                                        33
                                                              #cutoff surplus comma and carriage return
command is not
                                                              SET @sql = LEFT(@sql,length(@sql)-2);
                                                        35
36
37
supported in the
                                                              SET @sql = CONCAT(@sql,'\n',' FROM ', databasename,'.', 'tfm_vw_', tablename);
prepared statement
                                                             SELECT @sql;
protocol yet
                                                                                 mmand is not supported in the prepared statement protocol yet
                                                        42
                                                              #https://www.mysqlfaqs.net/mysql-faqs/Errors/ERROR-1295-(HY000):-This-com
                                                                 ARF cmd FROM Dsal
Jeg lærte at man ikke kan
                                                        44
                                                               XECUTE cmd:
danne sp'er gennem
sp'ere i MySql.
```

### Screnscraping data, etl og normalisering

Dette er en major showstopper ift. at bruge sp'ere som halv automatiserings grundlag. Vi kunne måske komme omkring det på mange måder, vi taler trods alt om et operatør drevent "API". Vi fortsætter og anvender en workaroud, der også viser dig hvordan du debigger store procedures.

Bemærk den gule pil i skærmbilledet ovenfor. I dette tilfælde selectere vi hhvad der står i vores dynamiske sql tekststreng.



Screnscraping data, etl og normalisering

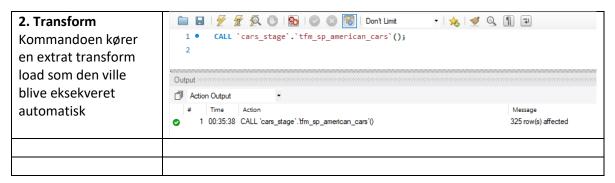
## Konklusion om replika et BI udviklingsflow

Der mangler mange ting endnu før vi kan sige at vi har det fulde featuresæt som er nødvendigt i et produktionsklar BI rådata lag.

- I alle sp'er der afvikles automatiseret, skal der laves try- catch og logges i en fejldatabase, måske er dette et domæne helt for sig selv, og kalder på oprettelse af en egentlig system database
- Vi har slet ikke favnet batch begrebet, som er nødvendigt når vi regelmæssigt importere data. Formålet er at danne historiske data, og det når vi ikke i denne replika, der kun håndtere en enkelt import.
- Historiske data dannes typisk i en merge mellem dat tabellen og vores eksisterende billede af hvad vi fandt sidste gang vi aflæste on-line.

### Afprøvning: Rådata ETL

Vi nåede endeligt til at skulle afprøve vores transform load.



Og dermed blev vi færdige med denne del af vores mainflow

